

Оценка погрешностей будущих измерений по имеющимся данным

Поляченко Юрий

10 апреля 2020 г.

1 Постановка задачи

Цель – предсказать погрешность ε выдаваемых нашей программой значений искомого параметра x .

Область изменения $x \in [0; 1]$ разбита на интервалы $[a_j; b_j]$, для каждого из которых есть N_j экспериментов. Считается, что искомая погрешность ε может меняться от интервала к интервалу, но постоянная внутри интервала. Фиксируем j и работаем в выбранном интервале, поэтому далее его индекс опущен.

Есть N экспериментов, про которые известно, что в каждом из них истинное значения x попало в интервал $[a; b]$. На каждый i -ый из этих экспериментов у нас есть результат работы нашей программы x_i . Предполагается, что истинное значение y_i распределено по гауссу со средним x_i и дисперсией ε . Ищем зависимость

$$\varepsilon(a, b, \{x_i\}_{i=1}^N, p_0) \quad (1)$$

такую, что

$$\mathcal{P}(\forall x \in [a; b] \mid x - y \mid < \varepsilon) = p_0 \quad (2)$$

Из сторонних соображений считается известным минимально возможная погрешность ε_{min} .

2 Предлагаемое решение

2.1 Приближение

Задав ε , можно посчитать вероятность реализации ситуации, описанной в постановке – попадание всех истинных значений y_i параметра, распределенных согласно результатам работы нашей программы по гауссу каждый около своего x_i , в интервал $[a; b]$. Далее предположение - эта вероятность равна нашей целевой вероятности p_0 . Не очевидно, почему это должно выполняться точно (скорее всего это не выполняется), но для оценки предложено использовать такую модель.

2.2 Расчет

Вероятность попадания i -ой истинной точки в интервал

$$p_i(\varepsilon) = \int_a^b g(x, x_i, \varepsilon) dx = \int_{(a-x_i)/\varepsilon}^{(b-x_i)/\varepsilon} g(x, 0, 1) dx, \quad (3)$$

где

$$g(x, \mu, \sigma) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left[-\frac{1}{2} \left(\frac{x - \mu}{\sigma} \right)^2 \right] \quad (4)$$

– гауссово распределение.

Введем

$$\text{erf}(x) = \int_{-\infty}^x g(t, 0, 1) dt. \quad (5)$$

Попадание каждого истинного значения в интервал – независимое событие, поэтому вероятность реализации нашего случая

$$p(\varepsilon) = \prod_{i=1}^N p_i(\varepsilon) = \prod_{i=1}^N \left[\text{erf} \left(\frac{b - x_i}{\varepsilon} \right) - \text{erf} \left(\frac{a - x_i}{\varepsilon} \right) \right] \quad (6)$$

Для нахождения желаемого ε_0 решаем уравнение $p(\varepsilon_0) = p_0$.

Очевидно, что

$$\left. \begin{array}{l} \forall \varepsilon > 0 \quad p'(\varepsilon) < 0 \\ \text{ran}[p(\varepsilon)] = (0; 1) \end{array} \right\} \Rightarrow \quad \forall p_0 \in (0; 1) \quad \exists! \varepsilon > 0 : p(\varepsilon) = p_0, \quad (7)$$

поэтому $\forall p_0 \in (0; 1)$ уравнение хорошо решается численно.



2.3 Пример

Для примера можно взять случайный набор из 10 точек в интервале $[0.25 \cdot 1.05; 0.5 \cdot 0.95]$ и считать, что их истинные значения принадлежат $[0.25; 0.5]$.




Рис. 1: Расположение 10 пробных точек в интервале $[0.25; 0.5]$.




Рис. 2: Зависимость $p(\varepsilon)$. Красная линия – принятая минимально возможная погрешность $\varepsilon_{min} = 0.02$, Синяя вертикаль – найденная оценка, синяя горизонталь – наш выбор $p_0 = (1 - \mathcal{P}_{gauss}(1\sigma))/2$, зеленый пунктир – минимальное расстояние точек до границы. Видно, что наличие множества точек позволяет улучшить оценку с очевидного значения минимального расстояния до границы – линия линия левее зеленой.

3 Результат применения

Можно исследовать, как оценка погрешности зависит от количества имеющихся экспериментальных данных в «усредненном» случае, когда ответы нашей программы расположены в интервале на равных промежутках.




Рис. 3: Равномерное расположение 10 пробных точек в интервале $[0.25; 0.5]$.

На глаз зависимость на рис.(4) близка к $1/N$, что ожидаемо, т.к. погрешность в основном определяется минимальным расстоянием до границы, которое при выбранной расстановке точек убывает как $1/N$.

Можно проверить отклонения от закона $1/N$ – рис.(5).

Видно, что наклон с правда близок к -1 , но небольшие отклонения от линейности есть.




Рис. 4: $\varepsilon(N)$




Рис. 5: $\varepsilon(N)$, логарифмический масштаб, попытка линеаризации